



中国科学院大学

University of Chinese Academy of Sciences

一种用于形变医学图像配准的 无监督学习模型

**An Unsupervised Learning Model for
Deformable Medical Image Registration**

Guha Balakrishnan
MIT

balakg@mit.edu

Amy Zhao
MIT

xamyzhao@mit.edu

Mert R. Sabuncu
Cornell University

msabuncu@cornell.edu

John Guttag
MIT

guttag@mit.edu

Adrian V. Dalca
MIT and MGH

adalca@mit.edu

小组成员：吴文霞，肖安琪，王国帅，蒲尧



中国科学院大学
University of Chinese Academy of Sciences

1

研究背景

2

研究方法

3

相关实验

4

总结展望

目录
Contents



01


研究背景

◎配准问题 ◎配准类型 ◎相关工作

1) 配准问题

- **配准问题：**
- 给定一个浮动图像（moving image）和一张固定图像（fixed image）。预测一个位移场，进而得到形变场（deformation field），即从浮动图像到固定图像的映射，使得配准后的浮动图像（warped image）和固定图像尽可能相似。

Deformable Image Registration



中国科学院大学

University of Chinese Academy of Sciences

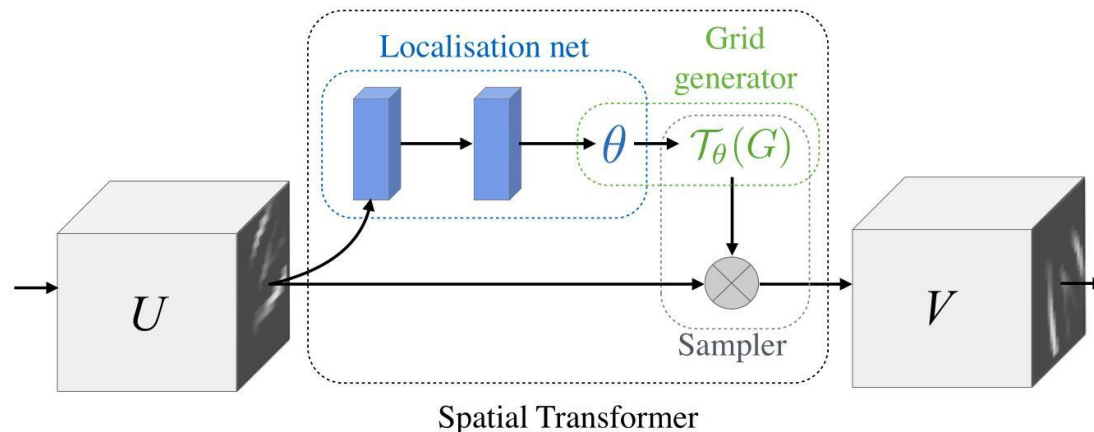
2) 配准类型

- **非学习配准**：基于数学优化的方法
 - 优点：通常效果比较好且稳定
 - 缺点：对每个图像进行迭代优化，耗时间较长
 - 典型模型：
 - 弹性模型 (elastic-type models)
 - 统计参数映射 (statistical parametric mapping)
 - b样条自由变形 (free-form deformations with b-splines)
 - 麦克斯韦妖 (maxwell's demons)
- **学习型配准**：通过神经网络训练的配准方法，利用大量的数据来训练一个模型，然后用这个训练好的模型对一个新的图像进行配准。这些方法大多依赖于 ground truth 扭曲区域或分割
 - 优点：训练过程缓慢，配准过程快很多
 - 缺点：训练数据较少，没传统方法稳定
- **有监督**：
 - 基于代理的行动学习实现非刚性配准
 - 利用形状匹配学习可变形图像配准
 - 基于多尺度三维卷积神经网络的非刚性图像配准
 - 快速预测图像配准-一种深度学习方法
- **无监督**：
 - 基于卷积神经网络的端到端无监督变形图像配准
 - 基于深度自监督全卷积网络的非刚性图像配准



3) 相关工作

- **光流估计：**
- 光流算法返回一个密集的**位移矢量场**，描绘了二维图像对之间的**小位移**。
- 传统的光流方法通常用变分方法解决优化问题。能更好地处理大位移或外观的戏剧性变化，包括基于特征的匹配和最近邻区域的匹配。
- Flownet: Learning optical flow with convolutional networks.
- Deepflow: Large displacement optical flow with deep matching.
- 缺点：需要在训练期间进行ground truth标注。



空间变换层：空间转换网络会根据位移场生成一个归一化后的采样网格，然后用该网络对图像进行采样，就得到了配准后的图像。

优点：使神经网络能够在**不需要监督标签**的情况下执行全局参数2D图像对准。

在本文的工作中，作者将空间变换扩展到3D场景。





02

研究方法

- ◎整体Pipeline
- ◎空间变换函数
- ◎网络结构
- ◎损失函数

1) 整体Pipeline

- Moving 3D → Fixed 3D
 - 使用CNN网络学习配准的体素空间变形场 ϕ
 - 空间变换保证映射后的位置落在标准像素点上
 - 用 ϕ 平滑loss损失

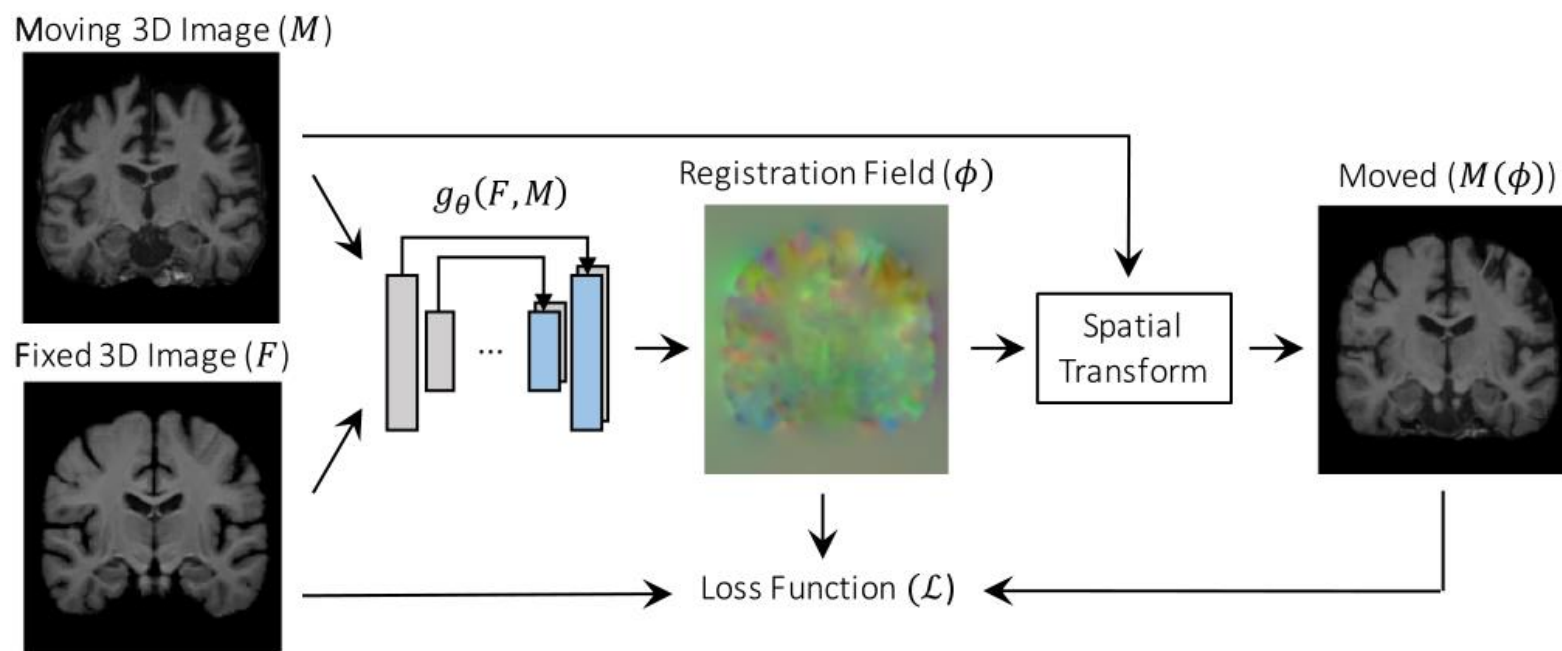


Figure 2: Overview of our method. We learn parameters for a function g that registers one 3D volume (M) to a second, fixed volume (F). During training, we warp M with ϕ using a spatial transformer function. Our loss compares M_{ϕ} and F and enforces smoothness of ϕ .

2) 网络结构

- 网络结构
 - 整体类似3D U-Net
 - VoxelMorph-1 & VoxelMorph-2
 - 平衡准确性和计算时间
 - VoxelMorph-2的结构更复杂
 - 卷积层更多 + 通道数更多
 - 更耗时 → 更准确
- Leaky ReLU激活
 - 相比ReLU不会出现“坏死”现象





Figure 3: Proposed convolutional architectures implementing $g(F, M)$. Each rectangle represents a 3D volume. The number of channels is shown inside the rectangle, and the spatial resolution with respect to the input volume is printed underneath. VoxelMorph-2 uses a larger architecture, using one extra convolutional layer at the output resolution, and more channels for later layers.

2) 网络结构

- 网络结构
 - 跳跃连接
 - 直接融合编-解码器间的特征
 - 帮助网络学习特征表示
 - 输入 $160 \times 192 \times 224 \times \underline{2}$
 - 2通道分别为M和F
 - 输出 $160 \times 192 \times 224 \times \underline{3}$
 - 为空间变形场 ϕ
 - 3通道分别为x/y/z三个方向位移
 - 卷积核 $3 \times 3 \times 3$
 - stride=2实现下采样
 - upsampling上采样




Figure 3: Proposed convolutional architectures implementing $g(F, M)$. Each rectangle represents a 3D volume. The number of channels is shown inside the rectangle, and the spatial resolution with respect to the input volume is printed underneath. VoxelMorph-2 uses a larger architecture, using one extra convolutional layer at the output resolution, and more channels for later layers.

3) 空间变换函数

- 解决 ϕ 映射后位置不在标准像素点上的问题
 - 保证训练能够按照梯度反传的方式进行
 - 计算一个在 M 上的体素 p 经过 ϕ 映射后 $\phi(p)$ 的位置 $M(\phi(p))$

$$M(\phi(p)) = \sum_{q \in \mathcal{Z}(\phi(p))} M(q) \prod_{d \in \{x, y, z\}} (1 - |\phi_d(p) - q_d|),$$

- 线性插值法
- $\mathcal{Z}(\phi(p))$ 是 $\phi(p)$ 的8-邻域体素



4) 损失函数

- 基于灰度值最大化一个关于图像间匹配程度的目标函数（无监督）

- 整体形式

$$\begin{aligned}\mathcal{L}(F, M, \phi) &= \mathcal{L}_{sim}(F, M(\phi)) + \lambda \mathcal{L}_{smooth}(\phi) \\ &= -CC(F, M(\phi)) + \lambda \sum_{p \in \Omega} \|\nabla \phi(p)\|^2,\end{aligned}$$

- 具体

- 相似性测度 \mathcal{L}_{sim} —— $M(\phi)$ 和 F 的负的局部交叉互相关 CC

- 值越大表示对齐越好
 - 对灰度强度变化更鲁棒

$$CC(F, M(\phi)) = \sum_{p \in \Omega} \left[\frac{\left(\sum_{q \in \mathcal{N}(p)} \hat{F}(q) \hat{M}(\phi(q)) \right)^2}{\left(\sum_{q \in \mathcal{N}(p)} \hat{F}(q)^2 \right) \left(\sum_{q \in \mathcal{N}(p)} \hat{M}(\phi(q))^2 \right) + \epsilon} \right], \quad (4)$$

- 空间平滑性约束 \mathcal{L}_{smooth} ——CNN空间梯度正则项

- 最大化相似性测度时容易引起网络产生不连续的变形场
 - 防止获得的 ϕ 不是连续的

$$\mathcal{L}_{smooth}(\phi) = \sum_{p \in \Omega} \|\nabla \phi(p)\|^2.$$





03

相关实验

- ◎数据集
- ◎结果分析
- ◎特定群体测试和超参敏感性分析

1) 数据集

- 实验选用了7829张T1加权的脑部MRI数据集，主要来自8个公开数据集ADNI，OASIS，ABIDE，ADHD200，MCIC，PPMI，HABS，and Harvard GSP，每个数据集的采集细节、受试者年龄范围和健康状况都不同。
- 在预处理阶段先将图像**重采样**为256×256×256大小，进行**仿射空间正则化**，并使用FreeSurfer工具**提取脑部（去除头骨）并获取分割结果**，再将结果图**裁剪**到160×192×224大小。训练集、验证集和测试集包含的图像数分别为7329,250和250。
- 采用**Dice Score**进行评价，可以衡量图像的重叠情况， $k=1\sim 29$ ，表示29个解剖结构， S 表示对应的数据集

$$\text{Dice}(S_{M(\phi)}^k, S_F^k) = 2 * \frac{S_{M(\phi)}^k \cap S_F^k}{|S_{M(\phi)}^k| + |S_F^k|}.$$



2) 结果分析

基于图谱的 (atlas-based) 配准实验, 图谱表示一个参考图像或平均图像, 通常是通过联合和反复校准 MRI 图像数据集并将它们平均在一起构建的。它和 fixed image 的作用相同, 但是 fixed image 只是一张图片, 而 **atlas 是图像数据集的平均**。

所有描绘大脑的图像都是二维冠状切片, 仅用于可视化目的。所有的配准都是3D的。

下表展示了采用不同模型: 仅仿射变换, ANTs (实现了对称归一化(SyN)方法), VoxelMorph-1,2的**平均DICE值和运行时间**:

Method	Avg. Dice	GPU sec	CPU sec
Affine only	0.567 (0.157)	0	0
ANTs	0.749 (0.135)	-	9059 (2023)
VoxelMorph-1	0.742 (0.139)	0.365 (0.012)	57(1)
VoxelMorph-2	0.750 (0.137)	0.554 (0.017)	144 (1)





Figure 4: Example MR coronal slices extracted from input pairs (columns 1-2), and resulting $M(\phi)$ for VoxelMorph-1 and VoxelMorph-2, with overlaid boundaries of the ventricles (yellow, orange) and hippocampi (red, green). A good registration will cause structures in $M(\phi)$ to look similar to structures in F . Our networks handle large changes in shapes, such as the ventricles in row 2 and the left hippocampi in rows 3-4.

2) 结果分析

采用不同配准方法，脑部不同结构配准效果的DICE值分布可视化



VoxelMorph模型在所有结构上都达到了与ANTs（实现了对称归一化(SyN)方法）相当的DICE测量值，在某些结构(如大脑白质)上的表现略好于ANTs，而在其他结构(如海马)上的表现则稍差。





3) 特定群体测试和超参敏感性分析

实验2：ABIDE数据集是有关自闭症群体的一个数据集，针对特定的ABIDE数据集测试特定群体方法的精度，可以看出DICE值提高了1.5%。

Table 2: Average Dice scores on ABIDE scans, when trained on all datasets (column 2) and ABIDE scans only (column 3). We achieve roughly 1.5% better scores when training on ABIDE only.

Method	Avg. Dice (Train on All)	Avg. Dice (Train on ABIDE)
VoxelMorph-1	0.715(0.140)	0.729(0.142)
VoxelMorph-2	0.718(0.141)	0.734(0.140)

实验3：右图表示，当Voxelmorph1 $\lambda = 1$, Voxelmorph2 $\lambda = 1.5$ 时，DICE得分最优。随着 λ 的增大，配准区域在结构边界处变得更加平滑。





中国科学院大学
University of Chinese Academy of Sciences

04

总结展望

◎前后对比 ◎后期工作

1) 前后对比

- 不基于学习是指传统的配准方法，每次配准都要对度量函数进行优化，**参数不共享**；
- 基于学习就是指经过神经网络训练的(训练就是学习)，训练出来的参数函数是共享的（**只需训练一次得到参数，以后配准都使用这些参数**）。
- 由于传统的配准方法是对**每一个图像对进行优化**，所以**速度非常慢**。有监督的神经网络训练的方式虽然提升了速度，但**需要大量的标注信息**；
- 无监督的神经网络训练具有**速度快、不需要标注信息**的特点。



2) 后期工作

VoxelMorph Papers

If you use voxelmorph or some part of the code, please cite (see [bibtex](#)):

- For the atlas formation model:

Learning Conditional Deformable Templates with Convolutional Networks

[Adrian V. Dalca](#), [Marianne Rakic](#), [John Guttag](#), [Mert R. Sabuncu](#)

NeurIPS 2019. [eprint arXiv:1908.02738](#)

- For the diffeomorphic or probabilistic model:

Unsupervised Learning of Probabilistic Diffeomorphic Registration for Images and Surfaces

[Adrian V. Dalca](#), [Guha Balakrishnan](#), [John Guttag](#), [Mert R. Sabuncu](#)

MedIA: Medial Image Analysis. 2019. [eprint arXiv:1903.03545](#)

Unsupervised Learning for Fast Probabilistic Diffeomorphic Registration

[Adrian V. Dalca](#), [Guha Balakrishnan](#), [John Guttag](#), [Mert R. Sabuncu](#)

MICCAI 2018. [eprint arXiv:1805.04605](#)

- For the original CNN model, MSE, CC, or segmentation-based losses:

VoxelMorph: A Learning Framework for Deformable Medical Image Registration

[Guha Balakrishnan](#), [Amy Zhao](#), [Mert R. Sabuncu](#), [John Guttag](#), [Adrian V. Dalca](#)

IEEE TMI: Transactions on Medical Imaging. 2019. [eprint arXiv:1809.05231](#)

An Unsupervised Learning Model for Deformable Medical Image Registration

[Guha Balakrishnan](#), [Amy Zhao](#), [Mert R. Sabuncu](#), [John Guttag](#), [Adrian V. Dalca](#)

CVPR 2018. [eprint arXiv:1802.02604](#)

<https://github.com/voxelmorph/voxelmorph>



中国科学院大学
University of Chinese Academy of Sciences

2) 后期工作

- 在新的工作中，作者提出了一个**概率模型**和**有效的学习策略**，可以**产生通用模板或条件模板**，并结合一个神经网络提供**有效的对齐图像到这些模板**。
- 这对于，不存在现有模板，或者使用传统方法创建一个新的模板可能非常昂贵，的临床应用，特别有用。




Figure 2: **Overview.** The network takes as input an image and an optional attribute vector. The upper network $g_{t, \theta_t}(\cdot)$ outputs a template, which is then registered with the input image by the second network $g_{v, \theta_v}(\cdot)$. The loss function, derived from the negative log likelihood of the generative model, leverages the template warped into $t \circ \phi_{v_i}$.

We optimize the neural network parameters θ using stochastic gradient algorithms, and minimize the negative maximum likelihood (1) for image x_i :

$$\begin{aligned} \mathcal{L}(\theta_t, \theta_v; v_i, x_i, a_i) &= -\log p_\theta(v_i, x_i; a_i) \\ &= -\log p_\theta(x_i | v_i; a_i) - \log p_\theta(v_i) \\ &= -\frac{1}{2\sigma^2} \|x_i - g_{t, \theta_t}(a_i) \circ \phi_{v_i}\|^2 - \gamma \|\bar{u}\|^2 - \lambda_d \frac{d}{2} \sum_i \|u_i\|^2 + \frac{\lambda_a}{2} \sum_i \|\nabla u_i\|^2 + \text{const}, \quad (6) \end{aligned}$$

where $g_{t, \theta_t}(a_i)$ yields the template at iteration i , and $v_i = g_{v, \theta_v}(t_{\theta_t, i}, x_i)$.

2) 后期工作




Figure 3: **MNIST examples** (1) MNIST digits from D-scale-rot; (2) templates conditioned on class (vertical axis) and scale (horizontal axis) on MNIST D-scale, learned with our model, and (3) with a decoder-only baseline model; (4) conditional templates learned with our model on the MNIST D-class-scale-rot dataset for the digit 3 and a variety of scaling and rotation values.

Experiment 1 on Benchmark Datasets: MNIST & QuickDraw

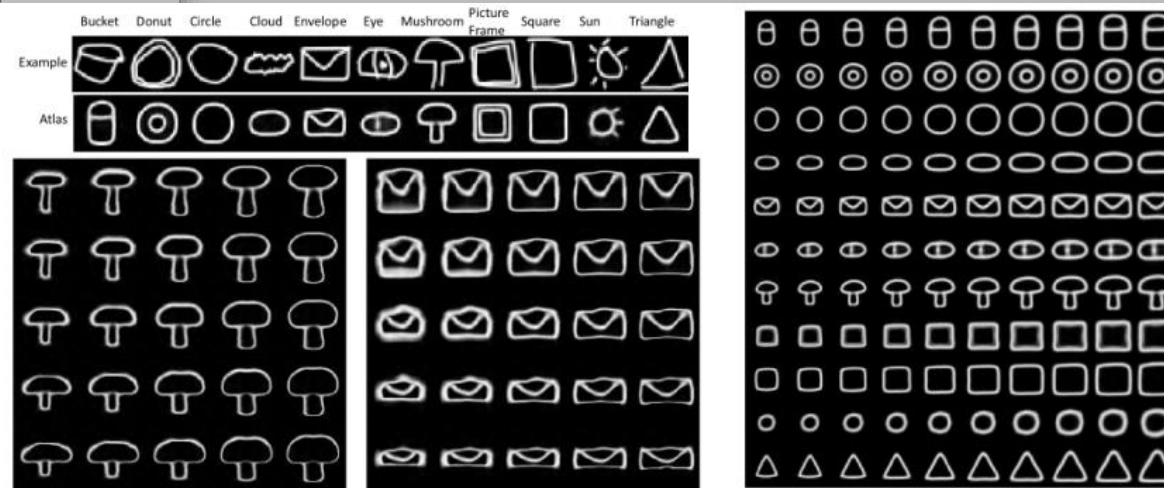


Figure 14: **Quickdraw example templates**. Left: example and learned atlases for the D-class QuickDraw dataset, and below variability examples similar to Figure 7-left. Right: templates for different scales and classes learned using D-class-scale simulations.

2) 后期工作

Experiment 2: Neuroimaging




Figure 13: **Volume trends.** Change in volume of ventricles and hippocampi of the age-conditional brain templates.




Figure 10: **Slices from Learned 3D Brain MRI templates.** Left: single unconditional template representing the entire population. Right: conditional age templates for brain MRI for ages 15 to 90, illustrating, for example, growth of the ventricles, also evident in a supplementary video.




Figure 11: **Segmentations.** Example segmentations overlaid with different brain views for our unconditional template (left) and conditional templates (right) varying by age.

参考文献

- [1] Balakrishnan G , Zhao A , Sabuncu M R , et al. An Unsupervised Learning Model for Deformable Medical Image Registration[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
- [2] Jek, zgün, Abdulkadir A , Lienkamp S S , et al. 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation[J]. Springer, Cham, 2016.
- [3] Dalca A V , Rakic M , Guttag J , et al. Learning Conditional Deformable Templates with Convolutional Networks[J]. 2019.





中国科学院大学
University of Chinese Academy of Sciences

感谢!