

基于改进的 U-Net 眼底视网膜血管分割*

梁礼明[†], 盛校棋, 郭 凯, 邓广宏

(江西理工大学 电气工程与自动化学院, 江西 赣州 341000)

摘 要: 针对视网膜血管图像特征信息复杂程度高, 现有算法存在微血管分割较低和病理信息误分割等问题, 提出一种融合 DenseNet 和 U-Net 网络的血管分割模型。首先, 通过限制对比度直方图均衡化和 filter 滤波对图像进行血管增强处理; 其次, 利用局部自适应 gamma 提升图像亮度信息并降低伪影的干扰; 再次, 由多尺度形态学滤波局部增强微血管特征信息; 最后, 利用 U 型密集连接模块进行分割。该算法在 DRIVE 数据集上实验, 其平均准确率、灵敏度和特异性分别高达 96.74%、81.50% 和 98.20%。

关键词: U 型网络; 视网膜; 血管分割; 形态学滤波

中图分类号: TP391.41 **文献标志码:** A **文章编号:** 1001-3695(2020)04-062-05

doi: 10.19734/j.issn.1001-3695.2018.09.0775

Improved U-Net fundus retinal vessels segmentation

Liang Liming[†], Sheng Xiaoqi, Guo Kai, Deng Guanghong

(School of Electrical Engineering & Automation, Jiangxi University of Science & Technology, Ganzhou Jiangxi 341000, China)

Abstract: In view of complexing feature information in retinal vessels and the existing algorithms have low microvascular segmentation and pathological information mis-segmentation. Thus, this paper proposed a vessels segmentation model based on DenseNet and U-Net networks. First, it performed image enhancement by restricting contrast histogram equalization and filter filtering. Secondly, it used local adaptive gamma to improve retinal image brightness information and reduce artifact interference. Then, multi-scale morphological filtering locally enhanced microvascular feature information. Finally, it segmented the optimized vessel image using a U-shaped dense connection module. The algorithm has an average accuracy, sensitivity and specificity of 96.74%, 81.50% and 98.20% by experimenting on the DRIVE dataset.

Key words: U-Net; retinal; blood vessels segmentation; morphological filtering

人的视网膜是一个具有极其丰富血管信息的光敏组织, 且是唯一具有非入侵和非创伤可视化性质的组织^[1]。通过对视网膜血管的数量、角度、分支、曲度等分析^[2], 能够辅助医生诊断患者疾病。因此, 视网膜血管系统的自动分析成为医学成像领域的热点话题。大多数现有的无监督与有监督视网膜图像分割方法都依赖于手工制作的特征来表征血管和非血管像素之间的差异。如基于多尺度匹配滤波的眼底分割方法^[3], 该方法利用分段线性近似呈高斯状强度分布的视网膜血管, 在阈值化之前增强血管, 虽然增强了大部分微小血管, 但仍存在血管交叉处分割不足、病灶误分割等现象。Soares 等人^[4]利用不同尺度 2D-Gabor 滤波是训练分类器实现血管像素检测的有效代替方案, 但此法仍存在微血管分割断裂的问题。其他的特征还包括脊特征^[5]、矩不变特征^[6]、局部相位特征^[7]、COSFIRE 滤波^[8]等, 可以较好地提取大部分血管特征, 但抗噪性较差, 易造成微血管分割断裂的现象。现有视网膜微血管通常具有较低的对比度, 并且与宽血管的强度差异往往大于背景的变化。此外, 还存在视盘、黄斑、病理和伪影等噪声的影响。虽然上述方法都取得了较好的分割效果, 但是这些人为选择的特征在解决这两个问题时, 仍然不能较鲁棒地解决血管变化趋势和血管信息的不变性, 造成微血管分割不足、病灶与视盘误分割等问题。近年来, 基于深度学习的特征学习方法被广泛地应用于眼底视网膜血管分割, 该类方法区别于人为的特征提取方法, 需另选较优的分类器完成最后的血管分割。其中深度学习

的卷积神经网络(convolutional neural network, CNN)将特征提取与分类器相结合, 具有更好的泛化能力和鲁棒性^[9]。Orlando 等人^[10]成功地将密集型条件随机场(conditional random field, CRF)模型与 CNN 相结合应用于视网膜血管分割, 该模型在图像内部建立远程链接, 因此较好地解决了收缩偏差的问题, 但存在病灶误分割的现象。Zhou 等人^[11]利用 CNN 提取血管特征和一组滤波器提升微小血管, 最后利用密集型 CRF 进行血管分割, 较好地解决了微血管分割不足的问题, 但仍存在部分微血管断裂、血管易链结等现象。

针对上述算法存在的不足, 本文提出一种在 U-Net^[12]框架下的 DenseNet^[13]的分割模型, 充分利用输出层的特征信息, 并在网络中加入空洞卷积提高网络提取血管特征信息的能力, 从而能更多地分割出微小血管。该方法融合限制对比度直方图均衡化(CLAHE)、filter 滤波和多尺度形态学滤波增强主血管与微血管信息; 通过局部自适应 gamma 校正, 纠正视网膜伪影区域。最终将以上处理结果利用 DenseNet-U-Net 模型进行分割, 较好地解决了微小血管分割不足、视盘与病灶误分割的难题。本文算法总体流程如图 1 所示。

1 视网膜图像分割原理

1.1 图像预处理

考虑到经过采集的视网膜图像存在光照不均匀、血管中心

收稿日期: 2018-09-15; 修回日期: 2018-11-14 基金项目: 国家自然科学基金资助项目(51365017, 61463018); 江西省自然科学基金面上项目(20192BAB205084); 江西省教育厅科学技术研究重点项目(GJJ170491)

作者简介: 梁礼明(1967-), 男(通信作者), 江西赣州人, 教授, 硕导, 硕士, 主要研究方向为医学图像分析与机器视觉(lianglm67@163.com); 盛校棋(1994-), 男, 山东青岛人, 硕士, 主要研究方向为医学图像处理与机器学习; 郭凯(1993-), 男, 山东聊城人, 硕士, 主要研究方向为机器学习与机器视觉; 邓广宏(1993-), 男, 河南信阳人, 硕士, 主要研究方向为机器学习和模式识别。

线反射等现象,从而造成微血管与背景对比度较低,进而使得算法鲁棒性不高,造成血管分割断裂和微血管分割不足等问题,故需对眼底视网膜图像进行预处理,才能获取较优异的血管特征,以便进一步处理。具体步骤如下:

a) 提取彩色眼底图像血管与背景对比度较高的绿色通道,并利用双边滤波对其进行降噪。

b) 对经过滤波去噪的绿色通道图像采取限制对比度直方图均衡化(CLAHE),在抑制噪声的同时提升血管与背景的对比度,然后经 filter 滤波对图像进行全局锐化,抑制 CLAHE 增强后图像的伪影与黄斑等噪声影响,突显血管信息。

c) 利用局部自适应 gamma 校正^[14]根据血管与背景的不同像素特征进行 gamma 值匹配,将视网膜图像分区域进行校正,使得光照不均匀因素与中心线反射现象加以抑制。

d) 将经过自适应 gamma 校正的图像,通过多尺度形态学 top-hat 变换^[15],进一步提升视网膜图像微血管信息。通过选取四个尺度,控制图像边缘梯度信息控制因子 w_i ,调整相邻血管像素尺度的差值,降低病灶与视盘等特征信息的干扰,提取微小血管的多尺度亮、暗细节特征。该模型定义为

$$f_T = I_r + k \times \sum_{i=1}^n w_i (\text{dop}_i - \text{dcl}_i) \quad (1)$$

其中: k 是视网膜血管图像细节增强因子; I_r 为输入图像; f_T 为输出图像; dop_i 与 dcl_i 分别为视网膜图像亮细节与暗细节特征。预处理结果如图 2 所示。

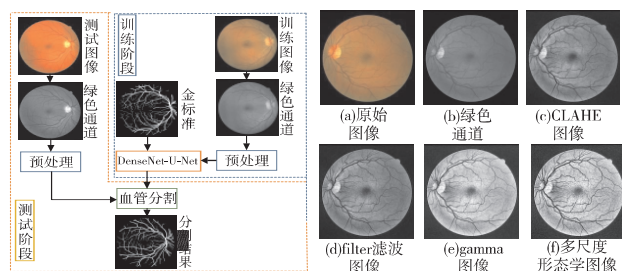


图1 总体流程

图2 预处理各阶段结果

Fig. 1 Overall flow chart Fig. 2 Preprocessing results for each stage

1.2 DenseNet-U-Net 模型

本文针对现有 U-Net 网络易对微血管分割产生断裂与视网膜眼底图像特征复杂性,引入 DenseNet 网络,增加网络信息重复利用率,使 U-Net 网络分割模型能分割出更多的血管信息。为了解决 U-Net 网络编码与解码过程中不能较好地保留图像细节特征而造成微血管分割断裂的现象,引入新的卷积层,利用空洞卷积代替 U-Net 网络中的卷积层,从而使视网膜图像训练在较少样本情况下得到最优分割。

1.2.1 U-Net 模型

U-Net 卷积神经网络的核心思想是利用较少的训练集进行端对端的训练,并且能有较好的输出结果。这种结构首先去掉了传统的全连接卷积神经网络(fully connected neural network, FCN)^[16]冗余的全连接层,只保留有效的卷积层,进而可以大幅度降低训练时间;然后,将网络中部分层的上采样层利用池化层代替,提高图片输出分辨率;最后,利用远程链接方式同时结合底层和高层信息,底层信息有助于提高训练精度,高层信息用来提取复杂特征,使得较浅层的网络可以达到深层网络的效果,得到更多的视网膜血管分割的细节。但该网络不能很好地恢复经池化层之后的图像细节结构信息,易造成微血管分割断裂的现象。

1.2.2 DenseNet 模型

DenseNet 的密集链接模块能将训练阶段视网膜血管图像的前层与本层的特征信息相结合作为下一层的输出,缩短前后层之间的距离,跨层连接时采用 concatenate 代替 element-wise

操作,从而加强特征传播的能力,使得网络特征重用,有利于减少网络参数和层数,降低算法整体复杂度。设 l 层的输出为 x_l , 定义为

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}]) \quad (2)$$

其中: $[x_0, x_1, \dots, x_{l-1}]$ 表示 $0, 1, \dots, l-1$ 层输出的特征层合并; $H_l(\cdot)$ 表示第 l 层的非线性映射,是多种操作的组合 BN→ReLU→conv。该模型可以较好地缓解梯度消失的问题,能够充分利用网络中所有输出特征图的信息。

1.2.3 空洞卷积

传统卷积神经网络的池化层有利于降低图像尺寸、增加特征图步长,但存在视网膜图像细节信息丢失,从而导致微血管分割不全和易发生断裂等问题^[17]。U-Net 网络通过上采样过程解决此问题,但网络层数越多其特征图也会越多,因此其并不能较好地恢复原图像的细节信息。故本文采用文献[18]提出的空洞卷积代替传统的卷积层,使本文算法能保留更多的图像细节信息,提升算法的泛化能力。

空洞卷积能在不增加算法参数复杂度的情况下使池化层拥有更大的感受野信息,并将图像全局信息都加以利用。其基本原理是在传统卷积核的每个像素之间插入值为 0 的像素,即增加网络的扩张率 r 。如图 3 所示,设一个卷积核,当 $r=1$ 时为 3×3 的空洞卷积核,当 $r=2$ 时为一个 5×5 的空洞卷积核。

1.2.4 DenseNet-U-Net 模型

针对现有卷积神经网络存在存储开销大、计算效率低等不足,本文提出将 U-Net 与 DenseNet 相结合,设计了一个 U 型密集链接模块(U-Net dense block, UDB)。该模型结合两者的优势,提高了网络的泛化性能,在减少训练时间的同时使得网络中每一层的血管特征都能得到充分利用,较好地解决了眼底视网膜图像存在病变与伪影的干扰,从而能更多地保留血管特征信息,获取更多微小血管,而且在训练集较少的视网膜图像中不易发生过拟合现象,提高了测试集的分割精度,具有较强的鲁棒性。本文算法网络模块如图 4 所示。




图3 空洞卷积示意图




图4 U型密集模块

Fig. 3 Sketch map of dilated convolution Fig. 4 U-shaped dense module

该模型以 U-Net 网络为主要框架, DenseNet 为辅。批量归一化(batch normalization, BN)用来降低模型训练中的协变转移,防止由于视网膜图像存在病理性噪声造成梯度消失,并且很好地保持了原有模型的表达能力; maxPool 表示池化层用来压缩特征图,降低复杂度; up-convz 表示上采样卷积,在每一个上采样后跟一个卷积,降低特征通道数。conv 表示卷积层,每一个卷积层利用线性修正单元(rectified linear unit, ReLU)进行特征提取,ReLU 能有效减少反向传播过程的梯度消失,降低网络计算复杂度,使得训练数据获得一定的稀疏性,其定义为

$$\text{ReLU}(x) = \max(x, 0) \quad (3)$$

由式(3)可知,当 $x < 0$ 时数据出现硬饱和状态,当 $x > 0$ 时导数值恒为 1,从而可以缓解在训练过程中梯度消失的问题。

该网络结构每个小块内均采用 DenseNet 的密集链接网络以确保最大的信息流,使得整个网络信息传播路径变得更短,因此可以减少输出层的特征数目,降低训练时间复杂度。每个函数 $H_l(\cdot)$ 会产生 k 个特征图,则 l 层会具有 $k_0 + k(l-1)$ 个特征图映射, DenseNet 网络可以设定一个固定增长率 K ^[13]来防止网络变得过宽,进一步提高网络的性能,从而可以提高小数据集训练的抗过拟合性。而 U-Net 的远程链接网络将编码部分和解码部分链接,确保低级信息加以利用。其中,在 U-

Net 模型中卷积层利用空洞卷积增加数据的感受野,但多个相同空洞卷积层叠加存在数据连续性差的缺点,故本文使用多种扩张率的组合,如在第一个 U 型密集链接网络使用扩张率为 1、2 组合的空洞卷积。

1.2.5 训练与分割

本文视网膜血管分割模型可大致分为编码器与解码器两大部分,主要目的是分类血管相邻的每一个像素将血管与背景分割。设经预处理的输入图像为 I_p ,将该图片进行归一化处理:

$$I = \frac{I_p - \mu}{\sigma}$$
 (4)

其中: μ 和 σ 分别表示数据的平均值与标准差。

然后,将归一化后的图像输入编码器部分。先经过带有 7 个 UDB 结构的网络层,设每次输出层的增长率 $K = 12$ 。每一结构包含两个空洞卷积层和一个 2×2 池化层进行下采样,将特征图降维到原来的 $1/2$,再将其输出加一个密集链接模块以便将训练所得血管特征重复利用。其次,由核大小为 3×3 上采样层进行图像解码,为防止上采样解码部分恢复原图像时信息丢失,使用一个 DenseNet 结构模型链接编码输出部分,使得与上采样层相同深度的特征层进行求和(图 5)。最后,由 soft-max 激活函数将血管与背景分类。

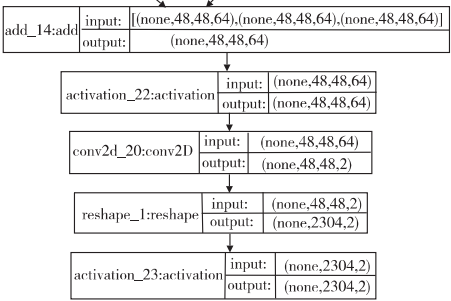


图 5 上采样合并特征过程
Fig. 5 Upsampling merge feature process

2 实验结果与分析

本实验的仿真平台为 PyCharm,使用 Keras 及其 Tensor-Flow 端口,计算机配置为 Intel® Core™ i7-7700 CPU@ 3.6 GHz,16 GB 内存,Nvidia GeForce GTX 1080 GPU,采用 64 bit Windows 10操作系统。

2.1 数据集

本文在 DRIVE(digital retinal images for vessel extraction) [5] 数据集上选取第一专家手动分割的眼底血管图像作为训练标签,第二专家手工分割的眼底图像作为最终分割结果的参考标准进行实验。DRIVE 于 2004 年由 Niemeijer 团队建立,分别包括 20 幅训练集图片和 20 幅测试集图片,其分辨率均为 565×584 。每幅图像对应两位专家的手动分割结果(金标准)。由于视网膜图像数据集过少,本文将图像以 45° 为旋转角度,将训练集扩充为原来的五倍,以进一步降低训练过程过拟合现象。

2.2 网络参数

本文采用 48×48 的滑动窗口,步长为 15,迭代 100 次即可达到理想训练精度。通过交叉验证来最小化像素分割错误率,采用 Adam 算法 [19] 优化损失函数,其学习率为 0.001。其中交叉验证定义为

$$J_{CE}(y, \hat{y}) = - \sum y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$
 (5)

其中: i 表示分类个数; y 为金标准; \hat{y} 为预测数据。

2.3 性能评价指标

为了系统定量地分析本文算法分割结果的性能,采取以下

三个指标作为衡量标准:

$$\text{sensitivity} = \frac{T_p}{T_p + F_N}, \text{specificity} = \frac{T_N}{T_N + F_p}$$
 (6)

$$\text{accuracy} = \frac{T_p + T_N}{T_p + T_N + F_p + F_N}$$
 (7)

其中: T_p 、 T_N 、 F_p 、 F_N 分别表示真阳性、真阴性、假阳性、假阴性;敏感度(sensitivity) 又称真阳性率,表示正确分类血管像素占真实血管像素的百分比;特异性(specificity) 表示正确分类的非血管像素占真实非血管像素的百分比;准确率(accuracy) 表示正确分类血管和非血管像素占整个图像总像素的百分率。

ROC(receiver operating characteristic) 曲线是一种衡量血管分割结果综合性能的重要标准,横轴为假阳性率(false positive rate, FPR),纵轴为真阳性率(true positive rate, TPR),反映不同阈值下两者的变化趋势,其值越大说明算法的分割性能鲁棒性越优异。

2.4 主观分析

图 6 展示了本文算法与文献 [20] 在 DRIVE 数据集上的部分图像的分割效果图。其中图 6(a) ~ (d) 中第一和第三幅图片为 DRIVE 数据集中第二与第四张健康视网膜图像; (a) ~ (d) 中第二与第四幅图片为 DRIVE 数据集中第三与第八张病变视网膜图片。图 6 中 (a) 为原始图像 (b) 为第二专家金标准图像 (c) 为利用文献 [20] 全连接 CRF 算法进行血管分割图 (d) 为本文算法分割图像。观察图 6(a) ~ (d) 中第一与第三幅健康视网膜图像可知,本文算法与文献 [20] 算法均取得较理想的分割结果,但文献 [20] 算法出现部分微血管断裂和视盘被误分割的现象,然而本文算法在微血管处分割数目较多且很好地解决了血管断裂的问题,基本避免了视盘被误分为血管的可能。本文算法对比图 6(b) 标准图像可以看出,本文算法的微血管分割结果的粗细相当,不会出现文献 [20] 算法微血管分割偏粗的现象,并且在微血管部分能分割出比金标准更多的细节结构。




图 6 不同算法分解结果比较
Fig. 6 Comparison of decomposition results by different algorithms

由图 6(a) ~ (d) 中第二与第四幅病变视网膜图像可观察到,此类视网膜图像存在一定量的硬性渗出物且总体图片较暗,尤其第四幅图片的视盘与病灶干扰因素较为严重。文献 [20] 算法的分割结果存在大量的病灶,尤其第四幅病变图像鲁棒性较差,实盘区域基本分割失效,而本文算法分割结果基本解决了视盘中心与硬性渗出物的影响,较好地还原了视网膜图像的血管结构。

为了更进一步清晰地展现出本文算法的优势,给出与第一专家分割为基准,在不同颜色下的血管对比图。其中绿色为分割正确的血管,红色为分割错误的血管,蓝色为多分割或误分割的血管(见电子版)。对比效果如图 7 所示。




图 7 其他算法与本文算法彩色对比
Fig. 7 Color comparison of other algorithms with this algorithm

由图 7 可以看出,本文算法相比 CRF 算法 [20] 与传统 U-Net 算法 [21] 能更多地分割出微小血管且微小血管不易断裂,误分

割率较低;CRF 算法在视盘处蓝色区域明显,而且多分割出的部分均为误分割,造成假阳性过高。

综上所述,本文算法不仅在健康视网膜图像上有较好的分割性能,且对病变视网膜能理想地分辨出病灶与血管特征,具有较强的鲁棒性和泛化能力。对于主血管末端的微小血管有较好的连通性与完整性,且分割结果不会出现过粗的现象,进一步说明本文算法在保持较高精度与灵敏度的情况下,能分割出较多的血管,拥有一定的临床应用价值。

2.5 客观分析

本文算法与其他文献方法的敏感度、特异性和准确率对比如表 1 所示,其中加粗的数据为本文算法。

表 1 不同文献方法之间性能数据对比

Tab. 1 Comparison of performance data between different algorithms

方法	acc	sen	spe	AUC
文献[9]	0.955 6	0.803 6	0.977 8	0.980 0
文献[11]	0.946 9	0.807 8	0.967 4	—
文献[21]	0.963 6	0.780 2	0.987 6	0.977 2
文献[22]	0.946 7	0.773 1	0.972 4	0.958 8
文献[23]	0.950 2	0.741 0	0.989 4	—
文献[24]	0.938 2	0.568 6	0.992 6	—
本文算法	0.967 4	0.815 0	0.982 0	0.980 8

由表 1 可知,现有的算法在 DRIVE 数据集上的血管分割准确率、灵敏度和 AUC 值均低于本文算法,说明本文算法在该数据集上具有较强的鲁棒性。文献[9]将残差学习和密集链接网络相结合,其 AUC 值基本与本文算法持平,但本文算法在灵敏度与准确率方面远高于此方法。文献[21]利用基本的 U-Net 网络结构,得到的分割精度与本文算法差距较小,其特异性高于本文约 0.005 6,几乎达到可以忽略的优势,但本文算法 AUC 值与灵敏度远高于传统 U-Net 网络结构的血管分割结果,说明了本文算法加入 DenseNet 与空洞卷积的必要性。文献[23-24]采用机器学习算法得到的特异性微高于本文算法,但本文的灵敏度远高于文献[23-24],说明 UDB 模型能分割出更多的微小血管,鲁棒性较强。

为了更直观地表现出本文算法的优势,给出图 8 所示的 ROC 曲线走势。由 ROC 曲线可以看出本文算法总体性能优越,假阳性率低,真阳性率较高,存在血管误分割的可能小。

图 9 给出本文算法与其他视网膜分割算法的 ROC 性能曲线对比。其中 UDB 为本文算法,DRIU(deep retinal image understanding)、HED(holistical-nested network)为深度学习算法,wavelets 为机器学习小波变换算法。从总体来看,深度学习算法远优于传统机器学习算法,但存在训练时间过长的缺点。本文 UDB 算法能在保证合理训练时间的情况下得到最优分割结果,100 张图训练仅用 6 h,测试阶段平均每张图约为 22 s。




图 8 DRIVE 数据集 ROC 曲线
Fig. 8 ROC curve of DRIVE dataset

图 9 其他算法 ROC 曲线比较
Fig. 9 Comparison of ROC curves for other algorithms

本文通过改变网络结构对本文算法作进一步评估。由于仅使用 U-Net 网络结构通过文献[21]已经得出了分割结果,故本文在 UDB 结构中去掉空洞卷积,换成传统卷积层得到分割结果 ROC 曲线,如图 10 所示。由图 8、10 相比较可知,在网络中使用空洞卷积层增加感受野比传统卷积层能得到更好的血

管分割效果。由表 1 中文献[21]与图 10 可知,仅加入 DenseNet 网络结构就远优于传统 U-Net 模型的分割结果,因此更能体现出本文总体算法的优越性。




图 10 传统卷积层的 UDB 网络结构 ROC 曲线
Fig. 10 ROC curve of UDB network structure with traditional convolution layer

3 结束语

眼底视网膜血管分割是医学领域人工分析走向自动诊断的重要过程。本文针对现有视网膜血管自动分割算法存在微血管分割不足、病灶与视盘易被误分割为血管的假阳性现象,提出一种基于 DenseNet 和 U-Net 网络的视网膜血管分割算法。首先利用限制对比度直方图均衡化(CLAHE)、filter 滤波增强整体视网膜图像对比度;然后利用局部自适应 gamma 校正视网膜图像的伪影;再利用多尺度形态学滤波局部增加血管与背景的对比度,进一步增加后续算法微血管处分割的鲁棒性;最后采用本文改进的 U-Net 网络进行血管分割,得到最终分割结果。本文分割算法将密集型链接网络引入到 U-Net 模型中,增加了特征信息的重复利用率,提高了分割结果的准确率,且极大地降低了网络参数的复杂度。利用空洞卷积代替传统卷积层增加池化层的感受野,能更好地提高算法的灵敏度,防止微血管分割断裂。该算法分割结果无须进行额外的后处理过程,说明算法对 DRIVE 数据集具有很好的鲁棒性和有效性,但对于带有病灶的图片仍会出现血管分割断裂的现象。如何提取病灶并修复病灶处血管断裂问题仍是以后视网膜血管分割研究需进一步解决的问题。

参考文献:

- [1] Zheng Yalin, Kwong M T, MacCormick I J C, et al. A comprehensive texture segmentation framework for segmentation of capillary non-perfusion regions in fundus fluorescein angiograms[J/OL]. PLoS One, 2014, 9(4). https://doi.org/10.1371/journal.pone.00.
- [2] 梁礼明, 黄朝林, 石霏, 等. 融合形状先验的水平集眼底图像血管分割[J]. 计算机学报, 2018, 41(7): 1678-1692. (Liang Liming, Huang Chaolin, Shi Fei, et al. Retinal vessel segmentation using level set combined with shape priori[J]. Chinese Journal of Computers 2018, 41(7): 1678-1692.)
- [3] Al-Rawi M, Qutaishat M, Arrar M. An improved matched filter for blood vessel detection of digital retinal images[J]. Computers in Biology and Medicine 2007, 37(2): 262-267.
- [4] Soares J V B, Leandro J J G, Cesar R M, et al. Retinal vessel segmentation using the 2D Gabor wavelet and supervised classification[J]. IEEE Trans on Medical Imaging 2006, 25(9): 1214-1222.
- [5] Staal J, Abramoff M D, Niemeijer M, et al. Ridge-based vessel segmentation in color images of the retina[J]. IEEE Trans on Medical Imaging 2004, 23(4): 501-509.
- [6] Marín D, Aquino A, Gegundez-Arias M E, et al. A new supervised method for blood vessel segmentation in retinal images by using gray-level and moment invariants-based features[J]. IEEE Trans on Medical Imaging 2011, 30(1): 146-158.
- [7] Låthén G, Jonasson J, Borga M. Blood vessel segmentation using multi-scale quadrature filtering[J]. Pattern Recognition Letters 2010, 31

- (8): 762-767.
- [8] Azzopardi G, Strisciuglio N, Vento M *et al.* Trainable COSFIRE filters for vessel delineation with application to retinal images [J]. *Medical Image Analysis* 2015, 19(1): 46-57.
- [9] 吴晨玥, 易本顺, 章云港, 等. 基于改进卷积神经网络的视网膜血管图像分割[J]. *光学学报* 2018, 38(11): 125-131. (Wu Chenyue, Yi Benshun, Zhang Yungang *et al.* Retinal vessel image segmentation based on improved convolutional neural network [J]. *Acta Optica Sinica* 2018, 38(11): 125-131.)
- [10] Orlando J I, Prokofyeva E, Blaschko M B. A discriminatively trained fully connected conditional random field model for blood vessel segmentation in fundus images [J]. *IEEE Trans on Biomedical Engineering* 2017, 64(1): 16-27.
- [11] Zhou Lei, Yu Qi, Xu Xun *et al.* Improving dense conditional random field for retinal vessel segmentation by discriminative feature learning and thin-vessel enhancement [J]. *Computer Methods and Programs in Biomedicine* 2017, 148(12): 13-15.
- [12] Ronneberger O, Fischer P, Brox T. U-Net: convolutional networks for biomedical image segmentation [C]//Proc of International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin: Springer 2015: 234-241.
- [13] Huang Gao, Liu Zhuang, Van Der Maaten L *et al.* Densely connected convolutional networks [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2017: 2261-2269.
- [14] 储清翠, 王华彬, 陶亮. 图像的局部自适应 gamma 校正 [J]. *计算机工程与应用* 2015, 51(7): 189-193, 208. (Chu Qingcui, Wang Huabin, Tao Liang. Local adaptive gamma correction method [J]. *Computer Engineering and Applications* 2015, 51(7): 189-193, 208.)
- [15] 刘艳莉, 桂志国. 多尺度 top-hat 变换提取细节的对比度增强算法 [J]. *计算机工程与设计* 2014, 35(4): 1332-1335, 1340. (Liu Yanli, Gui Zhiguo. Contrast enhancement using extracted details based on multi-scale top-hat transformation [J]. *Computer Engineering and Design* 2014, 35(4): 1332-1335, 1340.)
- [16] Fu Huazhu, Xu Yanwu, Wong D W K *et al.* Retinal vessel segmentation via deep learning network and fully-connected conditional random fields [C]//Proc of the 13th International Symposium on Biomedical Imaging. Piscataway, NJ: IEEE Press 2016: 698-701.
- [17] Long J, Shelhamer E, Trevor D. Fully convolutional networks for semantic segmentation [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press 2015: 3431-3440.
- [18] Chen L C, Papandreou G, Kokkinos I *et al.* DeepLab: semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs [J]. *IEEE Trans on Pattern Analysis and Machine Intelligence* 2018, 40(4): 834-848.
- [19] Kingma D P, Ba J. Adam: a method for stochastic optimization [EB/OL]. (2017-01-30). <http://arxiv.org/abs/1412.6980>.
- [20] Orlando J I, Blaschko M. Learning fully-connected CRFs for blood vessel segmentation in retinal images [C]//Proc of International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin: Springer 2014: 634-641.
- [21] Gao Xurong, Cai Yiheng, Qiu Changyan, *et al.* Retinal blood vessel segmentation based on the Gaussian matched filter and U-Net [C]//Proc of the 10th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics. Piscataway, NJ: IEEE Press 2017: 1-5.
- [22] Strisciuglio N, Azzopardi G, Vento M *et al.* Supervised vessel delineation in retinal fundus images with the automatic selection of B-COSFIRE filters [J]. *Machine Vision and Applications* 2016, 27(8): 1137-1149.
- [23] 蔡震震, 唐鹏, 胡建斌, 等. 基于 PST 和多尺度高斯滤波的视网膜血管的分割 [J]. *计算机应用研究* 2019, 36(6): 1893-1896. (Cai Zhenzhen, Tang Peng, Hu Jianbin, *et al.* Retinal vessel segmentation based on PST and multi-scale Gaussian filter [J]. *Application Research of Computers* 2019, 36(6): 1893-1896.)
- [24] 汪维华, 张景中, 吴文渊. 改进的形态学与 Otsu 相结合的视网膜血管分割 [J]. *计算机应用研究* 2019, 36(7): 2228-2231. (Wang Weihua, Zhang Jingzhong, Wu Wenyuan. New approach to segment retinal vessel using morphology and Otsu [J]. *Application Research of Computers* 2019, 36(7): 2228-2231.)
- (上接第 1246 页)
- [4] LeCun Y, Boser B, Denker J S, *et al.* Backpropagation applied to handwritten zip code recognition [J]. *Neural Computation* 1989, 1(4): 541-551.
- [5] LeCun Y, Bottou L, Bengio Y *et al.* Gradient-based learning applied to document recognition [J]. *Proceedings of the IEEE* 1998, 86(11): 2278-2324.
- [6] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [EB/OL]. (2015-04-10). <https://arxiv.org/abs/1409.1556>.
- [7] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks [J]. *Communications of the ACM* 2017, 60(6): 84-90.
- [8] Szegedy C, Liu Wei, Jia Yangqing *et al.* Going deeper with convolutions [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press 2015: 1-9.
- [9] He Kaiming, Zhang Xiangyu, Ren Shaoqing *et al.* Deep residual learning for image recognition [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2016: 770-778.
- [10] Zhang Xuyao, Bengio Y, Liu Chenglin. Online and offline handwritten Chinese character recognition: a comprehensive study and new benchmark [J]. *Pattern Recognition* 2017, 61(1): 348-360.
- [11] Xiao Xuefeng, Jin Lianwen, Yang Yafeng *et al.* Building fast and compact convolutional neural networks for offline handwritten Chinese character recognition [J]. *Pattern Recognition* 2017, 72(12): 72-81.
- [12] Szegedy C, Vanhoucke V, Ioffe S *et al.* Rethinking the inception architecture for computer vision [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press 2016: 2818-2826.
- [13] Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift [C]//Proc of the 32nd International Conference on Machine Learning. 2015: 448-456.
- [14] Szegedy C, Ioffe S, Vanhoucke V *et al.* Inception-v4, inception-ResNet and the impact of residual connections on learning [EB/OL]. (2016-08-23). <https://arxiv.org/abs/1602.07261>.
- [15] Srivastava R K, Greff K, Schmidhuber J. Highway networks [EB/OL]. (2015-11-03). <https://arxiv.org/abs/1505.00387>.
- [16] Srivastava R K, Greff K, Schmidhuber J. Training very deep networks [C]//Advances in Neural Information Processing Systems. 2015: 2377-2385.
- [17] Huang Gao, Liu Zhuang, Van Der Maaten L *et al.* Densely connected convolutional networks [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2017: 2261-2269.
- [18] Hu Jie, Shen Li, Sun Gang. Squeeze-and-excitation networks [C]//Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press 2018: 7132-7141.